2026 年全国大学生嵌入式芯片与系统设计竞赛

芯片设计赛道

技术 报告

作品名称（必填）：轻语：基于 E203 的前馈线性加速器

队伍编号（必填）：

参赛队名（必填）：

日期：2026 年 11 月 13 日

快速预览（一）：系统架构与设计要点

轻语：基于 E203 的前馈线性加速器

冻结版本：native12 earlycheck 版本日期：2026 年 11 月 13 日

本设计面向 KWT-1 语音指令识别模型的前馈网络第一线性层，实现 99×64 输入与 64×256 权重的矩阵乘法、偏置处理和定点转换，完整写回 99×256 个结果。E203 执行控制与驱动，加速器完成数值计算。本报告对应本科必做范围，不包含完整十二层编码器或语音分类硬件实现。

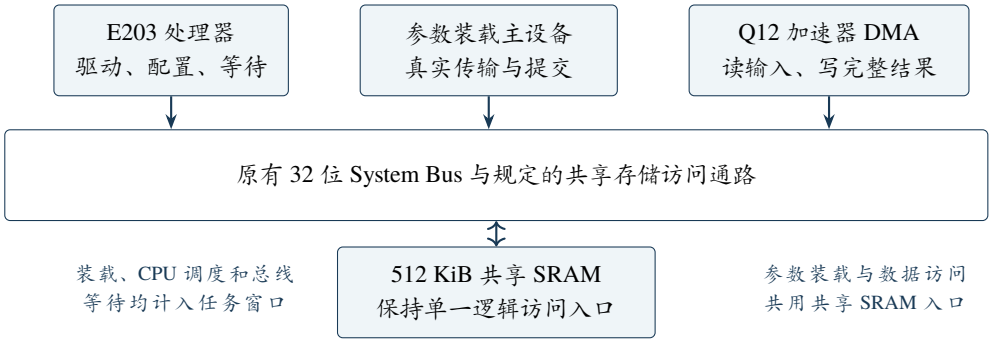


图 1 系统总线与共享 SRAM 连接结构。各主设备经规定通路访问共享存储。

设计要点。计算阵列采用 4×16 个成对乘积单元，复用行、列修正项；片内缓存通过读写调度实现权重装载与计算交叠；输出以固定 signed12 格式保存全部矩阵元素，不再进行 Rice、差分或变长压缩。

项目	本版实现	对应依据
数值配置	X12 / W10 / Y12，最近偶数舍入与饱和	源码与软件整数模型
计算组织	64 个 PE；16 个列 tile；每组最多 4 行	冻结 RTL
私有存储	19.5 KiB 物理容量；使用指定 SRAM 宏	宏实例与宽深配置
任务完成	全部结果写入后，等待最终完成标志的写响应	SoC 总线检查与物理读回

任务边界。一次任务包含参数装载、处理器调度、矩阵计算和完整写回。完成状态在最终写响应返回后发布，任务周期覆盖上述全过程。

快速预览（二）：性能指标与验证结果

指标	当前结果	解释
吞吐量	**6075.99 tasks/s**	150 MHz 换算，历史 12 个完整任务窗口
增量面积	**0.388582 mm^2**	新增逻辑与私有 SRAM，非整机面积
整机平均功耗	**约 58.36 mW**	包含 E203、互连及全部 SRAM
单任务能耗	**约 9.60 μJ**	同一网表的 12 窗口工程估计
DC setup / hold	$0/+0.00070456$ ns	已报告路径非负；未约束端点待复核

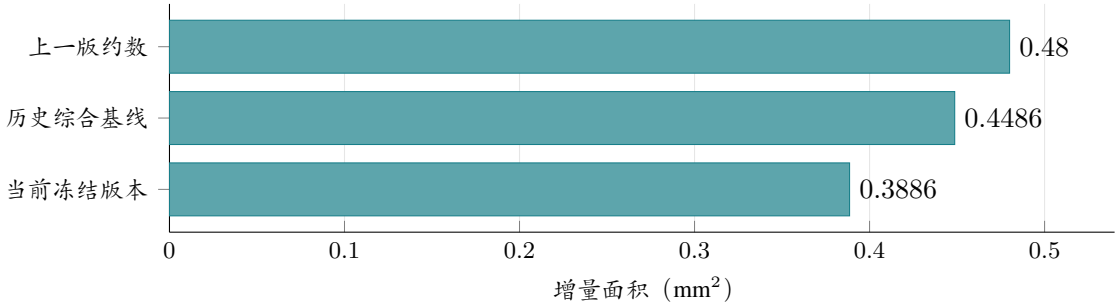


图 2 面积数值对比。0.48 为上一版实验记录的约数；不同版本并非单因素消融实验。

相比上一版约数 6000 tasks/s、0.48 mm^2，本版吞吐约提高 1.3%，面积约降低 19.0%；相对已核对的 0.448647 mm^2 综合基线，面积降低约 13.4%。当前能耗估计为 9.60 μJ，早期记录为 7 μJ；旧版测试配置和活动覆盖资料不完整，两者仅作数值参考。

功能验证。12 个本地合成任务及 12 个厂家 SRAM 模型任务逐值核对；每任务检查 25344 个输出值、总线事务守恒和最终物理 SRAM 内容；两种输出标识错误注入验证反压条件下的错误排空。

验证范围。正式 600 样本精度评测和 loader 平台接口验收尚未完成；时序未约束端点、等价未匹配点、功耗活动覆盖及库外推警告仍待复核。当前结果属于功能验证与综合阶段的测量结果。

版本标识。源码提交 `8731bf4`；版本标签 `q12-submission-20261113-r1`。本报告的吞吐、面积、时序和功耗均对应这一配置。

目录

快速预览 **1**

1 摘要 **4**
1.1 中文摘要 . . . 4
1.2 English Abstract . . . 4

2 设计平台与工具 **5**
2.1 任务范围与系统条件 . . . 5
2.2 测试配置与版本标识 . . . 5
2.3 测试数据集与统计范围 . . . 5

3 设计原理与系统组成 **6**
3.1 整体计算与控制流程 . . . 6
3.2 成对乘积与行列修正复用 . . . 6
3.3 并行阵列与分块调度 . . . 7
3.4 私有 SRAM 组织与读写调度 . . . 7
3.5 数值格式、舍入与误差来源 . . . 8
3.6 完整输出格式与地址映射 . . . 8
3.7 ICB 传输、反压和错误排空 . . . 9
3.8 固件寄存器与同步协议 . . . 9

4 验证过程与数据分析 **10**
4.1 验证层次和通过条件 . . . 10
4.2 计时窗口与吞吐量 . . . 11
4.3 面积统计与结构影响 . . . 11
4.4 150 MHz 约束与时序修复 . . . 12
4.5 功耗与能耗的计算口径 . . . 12
4.6 综合前后等价性及其边界 . . . 13

5 分析与讨论 **13**
5.1 版本对比与结果分析 . . . 13
5.2 吞吐瓶颈与优化顺序 . . . 14
5.3 规则核对与当前完成情况 . . . 14
5.4 设计总结与后续工作 . . . 14

6 工程文件与测试记录 **15**
6.1 工程版本与文件组织 . . . 15
6.2 测试记录说明 . . . 15

参考文献 **21**

1 摘要

1.1 中文摘要

针对端侧语音识别模型中的前馈线性计算，本设计在指定 E203 SoC 平台上实现一套定点矩阵加速器。计算范围为 99×64 与 64×256 矩阵相乘并加偏置，结果为完整 99×256 矩阵。系统采用 X12/W10/Y12 数值配置，以最近偶数舍入、算术移位和饱和处理完成数值转换。权重和偏置的格式转换采用固定规则，不进行重训、微调或按评测样本拟合参数。

计算阵列由 4×16 个成对乘积处理单元组成，利用行、列修正项复用减少矩阵计算中的乘法次数。输入、权重与元数据保存在指定 SRAM 宏构成的私有缓存中；装载控制与计算控制分离，权重通过四个槽位循环复用。DMA 保持原有 32 位 System Bus 访问通路，输入参数装载、CPU 调度、总线等待和完整结果写回均纳入任务窗口。输出使用每元素 12 位的固定数值格式，不再对结果进行独立压缩。

冻结版本在历史 12 个任务和厂家 SRAM 模型下通过完整数值及总线检查，平均任务周期为 24687.33，以 150 MHz 换算吞吐为 6075.99 tasks/s。官方 TT、1.10 V、25 °C 条件下，增量综合面积为 0.388582 mm^2，整机面积为 2.730734 mm^2。基于同版网表与 12 个任务活动窗口，整机功耗工程估计为 58.36 mW，平均单任务能耗为 9.60 μJ。已报告 DC 路径的 setup 和 hold slack 分别为 0 和 +0.00070456 ns，仍存在未约束端点；功耗活动覆盖、模型外推及等价未匹配点尚待复核。正式 600 样本精度评测尚未完成。

关键词： E203；前馈线性层；定点量化；成对乘积；System Bus；SRAM；综合评估

1.2 English Abstract

This work implements a fixed-point feed-forward linear accelerator on the prescribed E203 SoC platform. It computes a 99×64 input matrix multiplied by a 64×256 weight matrix, adds bias, and stores the complete 99×256 output matrix. The X12/W10/Y12 representation uses round-to-nearest-even and saturation. Weight and bias conversion follows fixed rules without retraining, fine-tuning, or fitting to evaluation samples.

The datapath contains a 4×16 pair-product array with shared row and column correction terms. Dedicated SRAM macros hold input, weight, and metadata buffers. Separate loading and computation controllers reuse four weight slots. All shared-SRAM traffic follows the original 32-bit System Bus path, and timing includes loading, CPU scheduling, bus stalls, and final writeback. Each output occupies a fixed 12-bit field; no separate output compression is applied.

The frozen design passed twelve historical full-task tests with vendor SRAM models. Its mean latency is 24687.33 cycles, corresponding to 6075.99 tasks/s at 150 MHz. At TT, 1.10 V and 25 °C, the incremental mapped area is 0.388582 mm^2, while total SoC area is 2.730734 mm^2. Twelve activity windows on the same netlist yield an engineering estimate of 58.36 mW and 9.60 μJ per task. Reported setup and hold slacks are 0 and +0.00070456 ns, respectively. Unconstrained endpoints, power-model warnings, strict equivalence review, and the official 600-sample accuracy evaluation remain open; the measurements are not presented as complete signoff.

2 设计平台与工具

2.1 任务范围与系统条件

赛题采用 KWT-1 开源预训练模型，前馈网络维度为 $64 \to 256 \to 64$。本设计覆盖本科必做的第一线性层，输入由指定模型的对应层处理流程离线提取；GELU、第二线性层、注意力和完整分类链路均不属于本版已实现范围 [1]。软件数值模型用于生成和核对参考值，不代替加速器必做计算。

平台保留 E203、原总线及外设框架，系统共享 SRAM 为 512 KiB。工作频率目标为 150 MHz；常开域低速时钟按照原平台保留。设计交付覆盖 RTL、功能仿真与逻辑综合，结果来自上述前端设计阶段的测量与检查 [4--6]。

表 1 工具和资源的职责分工

工具或资源	用途	验证资料
Verilator / Icarus	合成数据整机验证与定向检查	本地 12 任务结果、错误注入记录
Yosys	选定算术/局部变换的一致性检查	局部检查记录；不替代整机 LEC
VCS 与厂家 SRAM 模型	与宏时序行为相关的整机任务回放	12 个完整窗口、物理读回与活动文件
Design Compiler	同版整机综合、面积及约束检查	映射网表、SDC、setup/hold 与面积报告
Formality	RTL 与映射网表等价检查	通过点、未匹配点、黑盒与告警记录
PrimeTime 功耗分析	读取同版网表与活动估计整机功耗	12 窗口功耗、单位与覆盖检查
指定标准单元和 SRAM 库	综合映射和功耗/时序模型	TT、1.10 V、25 °C；宏实例计数

2.2 测试配置与版本标识

本版计算引擎文件的 SHA-256 为

`9447724c51ee9e4e80e72818cf1a448002b485fb00956be98d3f1a9f5848d432`

同一映射网表 SHA-256 为

`3eb43b4d79bbeb0389f4bb272e93629e7241dc1a6186c4e6c37a8b7bd448b712`

吞吐、面积、时序及功耗转录均绑定这一配置。原始网表、约束、活动及工具报告保留在授权服务器的独立运行目录，公开工程提供源码、固件、编译顺序、哈希清单和复现说明。工艺库、厂家模型及私有样本不随公开源码分发。

2.3 测试数据集与统计范围

测试分为历史任务回放与本地合成数据验证两组。前者采用冻结任务包和厂家 SRAM 模型，用于统计完整任务周期；后者采用合成数据与行为 SRAM，验证功能、边界条件和总线协议。历史任务集与组委会最终性能任务集相互独立。面积采用指定库条件下的逻辑综合结果，功耗采用布局前活动估计；本阶段尚无流片实测数据。

3 设计原理与系统组成

3.1 整体计算与控制流程

任务由 E203 通过 MMIO 启动。软件先建立任务 epoch 和装载请求，再配置输入基址、输出基址、总字数与已提交边界。装载主设备通过真实总线写入共享 SRAM，只有完成对应写响应后才发布可读边界。加速器仅访问已提交的数据范围；计算过程中软件继续提交后续权重块。最后完整矩阵写回并提交完成标志，E203 检查状态及格式头。



图 3 一次任务的完整流程。计算和装载存在重叠，图中顺序描述数据依赖，不表示所有阶段完全串行。

控制、DMA 和数值计算分别由 `qingyu_q12_stream_fio`、`q12_icb_stream_prefix` 与 `q12_task4` 等模块承担。原 E203 控制端与自有 DMA 入口分离，但计算输入、权重及结果全部经过规定的共享 SRAM 通路。输出矩阵由硬件生成，测试平台只提供输入和执行独立检查。

3.2 成对乘积与行列修正复用

对于长度 64 的整数点积，令 x_k 表示输入行、w_k 表示某输出列权重。按相邻元素成对分组，有

$$S = \sum_{k=0}^{31} (x_{2k} + w_{2k+1})(x_{2k+1} + w_{2k}), \tag{1}$$

$$R = \sum_{k=0}^{31} x_{2k} x_{2k+1}, \qquad C = \sum_{k=0}^{31} w_{2k} w_{2k+1}, \tag{2}$$

$$\sum_{k=0}^{63} x_k w_k = S - R - C. \tag{3}$$

展开每一对的乘积即可得到上述恒等式，因此重排本身不引入近似。对矩阵而言，R_i 在同一输入行的 256 个输出列之间复用，C_j 在同一权重列的 99 个输入行之间复用。偏置在修正之后加入，数值转换在最终结果端进行。

直接矩阵乘法需要 $99 \times 256 \times 64 = 1\,622\,016$ 次标量乘法。按该恒等式计数，主项为 811008 次，行修正 3168 次，列修正 8192 次，合计 822368 次，理论标量乘法次数减少约 49.3%。这个数字不包含流水寄存器、求和与修正开销，也不能直接换算成 49.3% 的面积或时延下降。

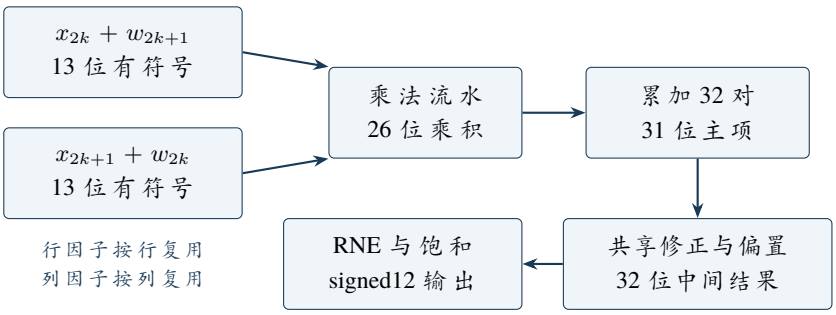


图 4 单个成对乘积通路及共享后处理。W10 数值在本冻结版缓存和 PE 输入处仍符号扩展为 12 位。

3.3 并行阵列与分块调度

阵列每次处理最多 4 行、16 列，共 64 个输出位置。256 列划分为 16 个 tile，99 行划分为 25 个行组，最后一组仅有 3 行有效。每个点积发出 32 对读请求，控制器根据有效行数屏蔽补齐位置。PE 接收 first/last 标记，first 使用零初值参与第一项累加，last 发布结果有效，避免跨任务残留数据进入有效结果。

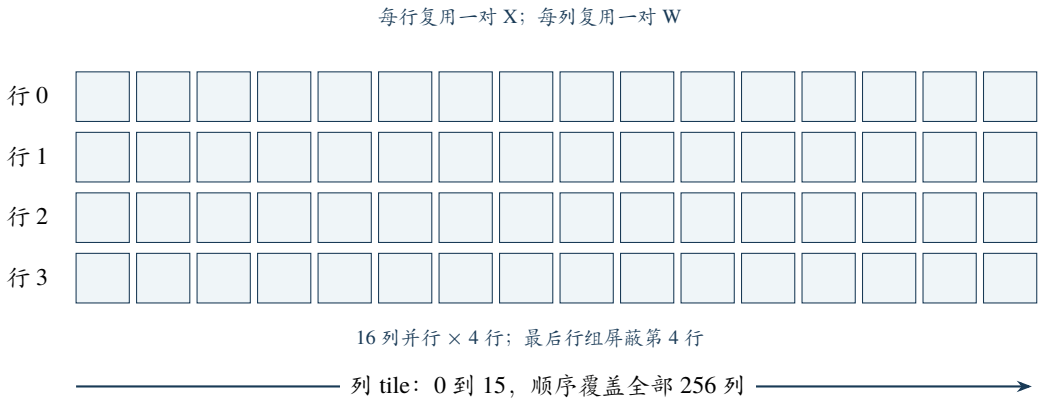


图 5 计算阵列组织结构。每个方框对应一个 PE，行间复用权重，列间复用输入。

阵列完成一组结果后，将 64 路主项及行因子转入显式结果快照。后处理端每次选择 4 个结果完成行列修正、偏置和量化，阵列可在下游允许时开始下一行组。输出快照保留 tile 和行组标识，后续写回使用相同标识检查，因此性能交叠不会改变矩阵元素的归属。

3.4 私有 SRAM 组织与读写调度

本版通过 16 位宏条带组合形成不同宽度的缓存。X 缓存按四行组织，在一个读请求中送出四对输入；权重缓存同时提供 16 列的权重对。私有权重槽位共四个，以 tile 标识和有效位管理占用状态：只有全部权重及元数据提交后才标记可用，只有对应 tile 的最终结果被接受后才释放。

表 2 冻结版本私有 SRAM 物理组织

用途	宽度 × 深度	宏组成	容量
输入 X	96 × 1024	6 个 RAMSP1024X16	12 KiB
权重 W	384 × 128	24 个 RAMSP128X16	6 KiB
行修正项	32 × 128	2 个 RAMSP128X16	0.5 KiB
列修正与元数据	64 × 128	4 个 RAMSP128X16	1 KiB
合计	–	30 个 128 深度宏及 6 个 1024 深度宏	19.5 KiB

权重装载端使用三个有界突发缓冲，每个缓冲聚集 8 个 48 位输入字形成一个 384 位写入字。只有计算侧不发起该缓存读操作的边沿才允许写入；元数据写入同样避开对应读取状态。内部独立存储通过调度实现装载与计算交叠，共享 SRAM 仍保持原有访问端口。

全 SoC 宏实例为 RAMSP128X16、RAMSP1024X16、RAMSP4096X16 各 30、6、80 个，共 116 个。共享 SRAM 的 64 个 RAMSP4096X16 保持不变，其余原平台存储随整机统计。本版私有 W 缓存保持 384 位物理宽度，元数据采用独立存储；面积统计包含这些宏的完整容量。

3.5 数值格式、舍入与误差来源

输入保留原 signed12 编码。对原整数权重 W_{12} 和偏置 b，转换定义为

$$W_{10} = \mathrm{sat}_{[-512,511]}\big(\mathrm{RNE}(W_{12}/4)\big), \tag{4}$$

$$b' = \mathrm{RNE}(b/4), \qquad s' = s - 1, \tag{5}$$

$$Y_{12} = \mathrm{sat}_{[-2048,2047]}\left(\mathrm{RNE}\left(\frac{XW_{10} + b'}{2^{s'}}\right)\right). \tag{6}$$

该转换的输出物理尺度为原 Y13 尺度的两倍。软件模型与 RTL 使用相同的低位舍入和饱和规则；输出尺度变化后，数值精度需按当前配置重新评估。权重除以 4 后在缓存中进行符号扩展，不会恢复丢弃的精度。

实现使用算术右移、guard 位、sticky 位和保留最低位判断进位。对半值采用偶数舍入，使正负方向具有一致规则；最终按 signed12 范围饱和。对于移位、饱和边界和符号扩展，验证以独立整数参考为准。成对乘积恒等式没有近似误差，主要数值误差来源是输入/权重量化、偏置转换、输出舍入和饱和。

正式精度应按每一层汇总全部 600 条样本的输出误差 RMS，并除以浮点参考 RMS（分母下限 10^{-8}），取 12 层中的最大值；本科门槛为 3% [1]。本版已完成整数参考模型一致性检查，正式浮点参考精度评估尚未完成。

3.6 完整输出格式与地址映射

共享 SRAM 按赛题要求保存完整输出矩阵 [2]。本版以固定 signed12 字段顺序保存每个元素，每 8 个元素恰好对应 3 个 32 位字；存储长度不依赖数值大小和零值比例。每个 tile 含 $99 \times 16 = 1584$ 个元素，即 19008 位、594 个 32 位字。

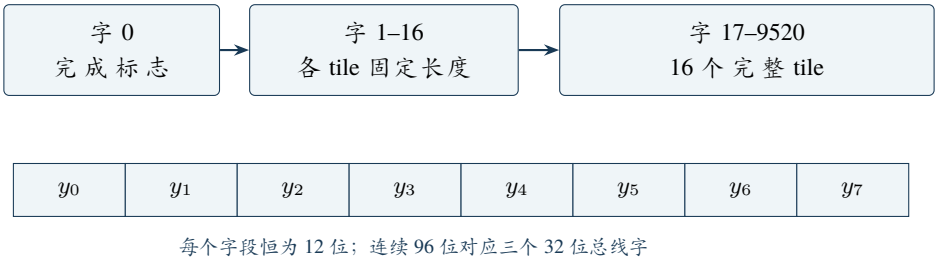


图 6 完整 signed12 输出布局，不采用结果熵编码或稀疏省略。

矩阵共 25344 个数，占 38016 字节；加上 17 字头部，分配空间为 38084 字节（9521 字）。任务开始时先使完成标志失效，结束时再次写入 `0x32443151`，因此任务实际写命令为 9522 次。16 个长度字段均为 19008，其单位是位，不是元素数。

设输出列 j 的 tile 为 $t = \lfloor j/16 \rfloor$，tile 内列 $c = j \bmod 16$，第 i 行对应位偏移为 $b = 12(16i + c)$。以 32 位字为单位，目标字偏移为

$$a = 17 + 594t + \lfloor b/32 \rfloor, \qquad r = b \bmod 32.$$

读取该字及必要的下一字，右移 r 后取低 12 位并符号扩展，即可直接得到 $Y_{i,j}$。固定下标读取不需要压缩解码器。输出写回采用完整长度检查及最终响应确认，计时终点设在最后一个写响应返回时。

3.7 ICB 传输、反压和错误排空

DMA 使用 4 项在途请求记录、16 字读缓冲和 8 字写缓冲。每笔命令记录读写归属和结束标记，响应必须按对应归属消费。若总线没有接受已提出的命令，地址、读写方向和载荷保存在保持寄存器中，直到握手完成。新请求选择采用已就绪输出写优先，降低结果反压；该策略只作用于自有 DMA，不改变下游官方总线位宽和协议。

输出标识检查同时核对 tile、字索引与范围。原实现把标识检查使能与 formatter ready 相连，错误排空又影响 ready，形成组合反馈。本版改为只要输出有效即检查标识，再独立产生错误控制，正常任务的有效握手和周期不变。

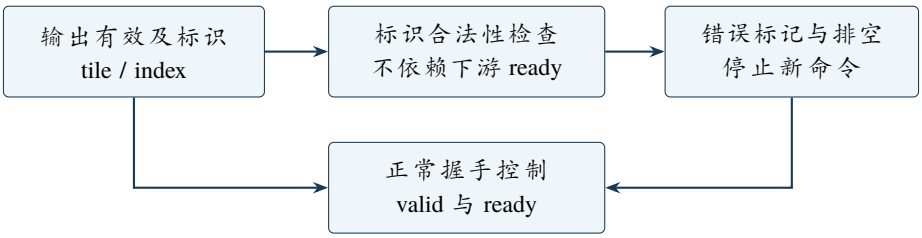


图 7 本版错误检查依赖关系。检查逻辑不再从 ready 取得使能，切断原反馈环。

发生错误后系统停止产生新命令，继续接收已发出的响应并排空在途记录；失败任务不能发布有效完成矩阵。分别在 ready 为 1 和 0 时注入非法输出索引的整机测试均通过，观测到 5 周期排空，已发命令数与响应数分别保持 2046/2046 和 2047/2047。

3.8 固件寄存器与同步协议

软件配置接口位于 `0xf0000000`，装载邮箱位于 `0xf0020000`。输出区域从 `0xa0000000` 开始，输入区从 `0xa0040000` 开始，控制记录位于 `0xa0030100`。驱动以 `fence rw,rw` 保证提交记录与后续访问的顺序，epoch 避免旧任务就绪记录被新任务误用。

表 3 加速器关键控制寄存器（相对配置基址）

偏移	用途	行为说明
0x00	标识	读回 0x51313231
0x04	启动/清状态	空闲时接受启动，拒绝忙态非法重配
0x08 / 0x0c	输入/输出基址	启动前配置，4 字节对齐
0x10 / 0x14	状态/阻塞等待	状态含忙、完成、错误；WAIT 等待完成或错误
0x18	任务计数	加速器内部周期诊断，不替代系统完整窗口
0x34 / 0x38	总输入字数/epoch	限定数据范围及任务标识
0x3c / 0x40	可读边界/提交 epoch	只扩展已实际提交的数据边界

CPU 通过阻塞 WAIT 减少重复轮询，但仍检查实际共享控制记录和最终输出头。驱动采样的周期与测试平台完整窗口具有不同边界，吞吐统计采用测试平台记录的完整任务窗口。

4 验证过程与数据分析

4.1 验证层次和通过条件

验证按数值单元、格式与协议、完整 SoC、厂家模型、综合网表五个层次组织。软件整数点积与 RTL 中的成对乘积实现相互独立，输出读取按固定下标解释共享 SRAM 内容。测试同时覆盖复位、边界、反压、非法结束和错误排空，并逐元素检查输出矩阵。

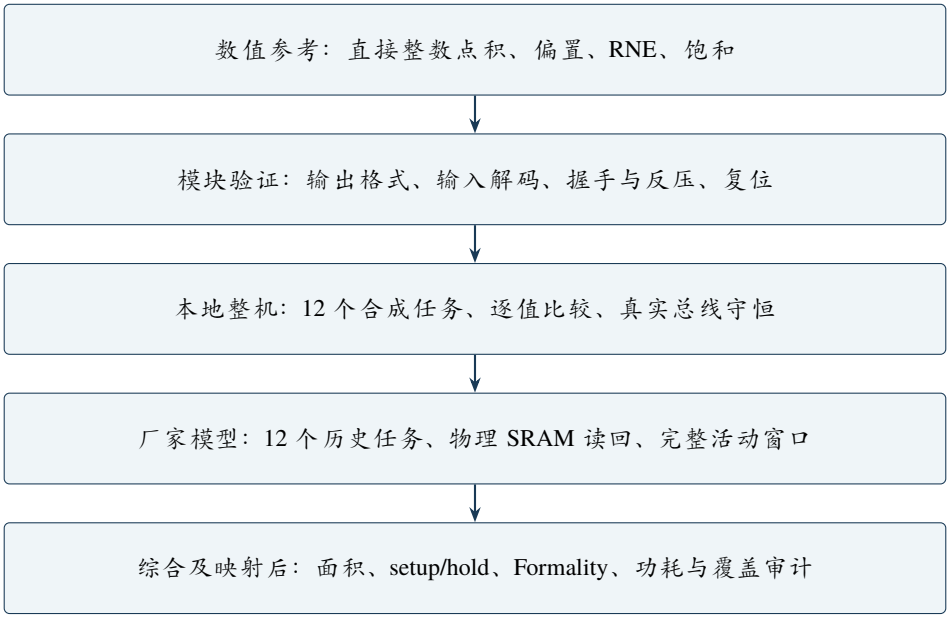


图 8 分层验证流程。依次进行数值单元、总线协议、整机功能和综合网表检查。

本地 12 个合成任务的均值为 25647.75 周期，厂家历史 12 任务均值为 24687.33 周期。两组输入分布不同，输入编码长度和总线流量随之变化，其周期差异与任务数据有关。两组都比较全部输出值，各自覆盖 $12 \times 25344 = 304128$ 个数值。

表 4 本版功能与综合检查状态

检查项	结果	解释
本地整机 12 任务	通过	行为 SRAM、合成数据，输出及总线检查
厂家模型 12 任务	通过	完整写回及物理读回，正常周期与父版逐项相同
错误标识注入	2/2 通过	ready=1/0 均排空，不发布完成矩阵
Formality 工具比较	35565 通过，0 失败	仍有未匹配、unread 与解释告警，严格审计未通过
正式 600 样本精度	未完成	待完成浮点参考误差统计

4.2 计时窗口与吞吐量

赛题要求从输入和参数开始装载计时，到结果全部写回结束，包含装载、总线等待与 E203 调度 [1,2]。本版测试保留真实加载请求、共享存储写入、DMA 读回和结果写入的事务计数。任务间复位不计入运行时间，计算机端文件读取及一次性格式转换不计入硬件窗口。

令第 i 个任务耗费 N_i 个系统时钟周期，时钟频率为 f，则

$$T_{\text{task}} = \frac{\sum_i N_i}{Mf}, \qquad \text{Throughput} = \frac{Mf}{\sum_i N_i} = \frac{f}{\overline{N}}.$$

取 $M = 12$、$f = 150 \times 10^6$ Hz 和 $\overline{N} = 24687.3333$，得到 6075.99 tasks/s。最慢任务为 24802 周期，最快为 24533 周期。该换算以 150 MHz 为条件，完整时序约束的检查范围见时序分析小节。

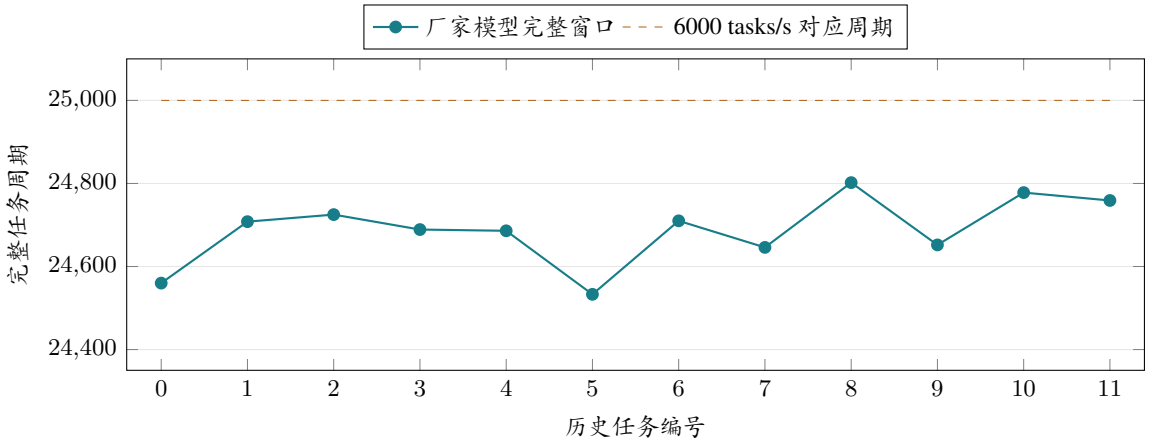


图 9 12 个历史任务的完整周期分布。虚线为 6000 tasks/s 对应的 25000 周期预算，纵轴范围为 24350–25100。

4.3 面积统计与结构影响

赛题的加速器面积包括新增计算逻辑、接口和内部 SRAM；复用 E203、512 KiB 共享 SRAM、固定总线及外设面积单列 [1]。本版在同一网表上分别统计加速器增量面积和整机总面积，SRAM 宏按实例归属计入各分项。

表 5 同版综合面积明细

项目	面积（μm^2）	面积（mm^2）
加速器及私有存储	384884.747634	0.384885
NP3 仲裁逻辑	1113.050400	0.001113
共享路径新增非宏逻辑	2584.562400	0.002585
增量合计	388582.360434	0.388582
全 SoC 合计	2730733.915310	2.730734

增量综合面积低于赛题规定的 2.25 mm^2 上限。成对乘积、行列修正复用、寄存器有效位管理及输出格式共同决定映射结果。当前统计针对完整配置，尚未进行各项结构改动的独立面积消融实验；最终物理面积仍需结合布局布线结果评估。

4.4 150 MHz 约束与时序修复

目标周期为 6.666666667 ns，setup 不确定度为 0.1 ns、hold 不确定度为 0.02 ns；数据 I/O 延迟未放宽。loader 导出时钟用 1:1 generated clock 表达，移除误加在该时钟输出上的数据输出延迟。四个 PWM 异步同步器第 0 级入口按异步来源单独约束，后续同步级继续计时，未对加速器、SRAM 或总线数据通路设置泛化 false path。

早期中间版存在 -0.14896035 ns 的 SRAM 数据 hold 违例。切断 ready/abort 反馈后完成同版重新综合及 hold-only 修复，最差已报告 setup 为 0 ns、hold 为 +0.00070456 ns。保持裕量约 0.70 ps，对工艺角、时钟关系和布线延迟变化较为敏感。

表 6 时序结果与覆盖限制

项目	当前观测	解释
已报告 setup	0.00000000 ns	达到当前约束边界，裕量为零
已报告 hold	+0.00070456 ns	SRAM 真实数据路径修复后非负
组合环检查	原反馈环告警消除	错误检查不再依赖 ready
未约束端点	UART、AON 等仍列出	3 路 UART 的 24 个锁存器 D 端、2 个 AON 异步入口及 loader 时钟输出需要分类复核
完整时序验收	尚未完成	尚有未约束端点待检查

原平台外设锁存器与异步输入尚需按功能、工作模式和时钟关系补充约束分析。当前未约束端点仍保留在检查报告中，全 SoC 时序验收尚未完成。

4.5 功耗与能耗的计算口径

功耗使用同版综合网表和同一任务窗口的 cell-aware SAIF，统计 E203、加速器、互连及全部 SRAM 的动态和静态功耗，不包含模拟模块或片外设备。功耗模型覆盖全部 116 个 SRAM 宏实例，宏活动来源纳入覆盖检查。

令窗口长度为 Δt_i，该窗口整机平均功耗为 P_i，则

$$\overline{P} = \frac{\sum_i P_i \Delta t_i}{\sum_i \Delta t_i}, \qquad \overline{E} = \frac{\sum_i P_i \Delta t_i}{M}.$$

12 个窗口得到时长加权平均功耗 58.3583 mW、平均能耗 9.60339 μJ。根据原功耗报告 Total Power 的

有效数字，结果取 58.36 mW 与 9.60 μJ。窗口 ps 时长与理想整数周期换算存在时钟仿真精度引起的微小差别，能耗使用实际记录时长。

表 7 12 个历史完整任务及对应功耗窗口

任务	周期	窗口（μs）	功耗（mW）	能耗（μJ）
00	24560	163.710294	58.50	9.577052
01	24708	164.696862	58.40	9.618297
02	24725	164.810184	58.40	9.624915
03	24689	164.570208	58.40	9.610900
04	24686	164.550210	58.30	9.593277
05	24533	163.530312	58.30	9.533817
06	24710	164.710194	58.30	9.602604
07	24646	164.283570	58.20	9.561304
08	24802	165.323466	58.40	9.654890
09	24652	164.323566	58.40	9.596496
10	24778	165.163482	58.30	9.629031
11	24759	165.036828	58.40	9.638151

首窗口 `check_power` 报告 215 个 slew 超表、2685 个负载超表及 3 个无逻辑函数库单元；活动来源属性与当前工具版本存在兼容问题。活动覆盖和模型外推警告尚待复核，当前功耗与能耗属于工程估计，尚未达到签核条件。

4.6 综合前后等价性及其边界

同一 RTL、mapped.v 和 mapped.svf 的 Formality 工具结果显示 Verification SUCCEEDED，35565 个比较点通过、0 个失败点。然而仍有 625 个 unread 点、9 个仅参考侧未匹配寄存器及 RTL 解释告警。9 个未匹配点分布在原总线合并控制、AON PMU 计数器与输入解码器状态中，尚未逐项完成独立判定。

SRAM 采用两侧对应的对称黑盒，黑盒匹配完成；没有 dont_verify 点和用户定义常量。该证明范围止于 SRAM 边界，并不证明宏内部实现。未匹配点及 RTL 解释告警仍待逐项分析，严格等价验收尚未完成。

5 分析与讨论

5.1 版本对比与结果分析

表 8 历史数值与本版结果对比

版本或记录	吞吐（tasks/s）	面积（mm^2）	能耗（μJ）
本版冻结配置	6075.99	0.388582	9.60*
历史综合面积基线	–	0.448647	–
上一版记录（约数）	6000	0.48	–
早期版本记录	4700	0.38	7

* 本版能耗为整机工程估计。其余历史记录缺少同网表、同窗口、同角及活动覆盖报告；“–”表示无对应测试记录。

本版面积相对已核对基线减小约 13.4%，相对上一版约数减小约 19.0%；吞吐略高于 6000 tasks/s。当前能耗估计高于早期记录，但旧版本缺少可复核的同口径报告，不能将两者之差直接归因于某项

RTL 改动。不同版本的输出格式、任务窗口、数值精度与验收条件需要一并比较。

任务能耗由平均功耗与任务时长共同决定。逻辑面积减小后，若运行时间或存储访问次数增加，整机静态功耗与处理器运行开销仍可能抵消局部节省。本版完整输出具有固定的总线写入量，与旧版压缩输出的访存负载不同。能效分析因此采用完整任务窗口内的整机能量作为指标。

5.2 吞吐瓶颈与优化顺序

在 150 MHz 下达到 6000 tasks/s 的平均周期预算为 25000，本版均值距离预算只余约 313 周期。达到 10450 tasks/s 则平均周期需降至约 14354，要求比当前减少约 41.9%。计算阵列按 25 个行组、16 个列 tile、每点积 32 对计算，仅主计算读请求就有 12800 个发出周期；这一计数仅覆盖主计算请求，端到端任务还包含装载、状态切换、后处理和完整写回。

输出本身固定需要 9522 个写命令。共享 SRAM 保持单一 32 位访问入口，因此增加更多 PE 并不保证端到端吞吐同比增加。性能分析应分别统计总线空泡、已提交数据等待和输出反压，并结合阵列占用率确定瓶颈。当前仅有完整任务周期记录，各类等待的周期分解尚待补充。

可以继续研究的方向包括：在原协议能力内提高请求连续性；缩短提交和状态切换空泡；在完整输出不变的前提下压缩私有缓存冗余位；减少不必要的数据翻转。每一方向都必须重跑同版功能、150 MHz 时序、面积和能耗检查。共享 SRAM 直连、扩大接口位宽或省略输出值不属于可采用的优化路径。

5.3 规则核对与当前完成情况

表 9 与赛题要求对应的实现和边界

项目	本版处理	状态
第一线性层	完成矩阵乘法、偏置、量化及完整输出，CPU/TB 不代算	整数功能通过
多层参数切换	历史包覆盖 12 个对应任务，每任务真实装载	历史验证通过
不重训规则	固定离线 RNE 变换、重排与输入打包	有转换脚本；正式精度待测
完整输出	25344 个固定 signed12 字段，无另行压缩	已实现及物理读回
规定通路	保持 32 位 System Bus 与共享 SRAM 逻辑入口	总线路径保持；loader 接口待验收
完整计时	输入/权重装载、等待、调度及最终写响应计入	历史窗口已记录
150 MHz	已报告 setup/hold 非负，仍有未约束端点	全约束验收未完成
面积上限	增量 0.388582 mm^2，上限 2.25 mm^2	该配置综合数值满足
整机功耗	含 CPU、互连和所有 SRAM，12 窗口同网表	估计完成，覆盖与模型警告待复核
数值门槛	600 样本、逐层 NRMSE 最大值不超过 3%	未完成
同版一致性	配置、源文件和网表哈希绑定	采用统一冻结配置

5.4 设计总结与后续工作

本设计完成了 E203 控制、总线 DMA、成对乘积阵列、私有缓存和完整输出写回的系统集成。统一的任务边界覆盖参数装载与最终写响应，固定输出格式支持逐元素物理读回。源码、综合网表和活动窗口采用版本标识及哈希关联，使功能验证与性能统计对应同一配置。

后续工作包括正式 600 样本精度评测、外设未约束端点分析、等价未匹配点复核，以及功耗活动覆盖和模型超表检查。性能优化重点为总线请求连续性、装载与计算交叠、输出反压及私有缓存冗余位。各项修改均需在统一配置下重新完成整数功能、时序、面积和能耗测试。

6 工程文件与测试记录

6.1 工程版本与文件组织

公开仓库冻结提交为 8731bf4，完整提交标识如下：

8731bf4f553e80a1ac5e68fb924b0436ddbdb77f

交付入口 final/q12_submission_20261113/ 包含完整源文件树、固件、编译顺序、验证脚本和冻结清单。文件 FREEZE_MANIFEST.json 对 169 个源及证据文件记录哈希，交付清单进一步绑定报告和原始图片。

测量记录由 earlycheck_observation.json、power_observation.json 和原始工具报告组成。数据表按相同公式进行单位换算、周期统计和能量计算。截图记录不同测试阶段；功耗首轮恢复错误及等价验证中间状态与后续完成结果分别留存。

表 10 验证脚本及功能

入口	作用与依赖
final/.../verify.py	核对工程文件 SHA-256，检查版本完整性
run_local.py	以 --storage-bits 12 --weight-bits 10 --write-priority --early-output-check 生成同候选的合成任务验证
check_output_fault.py	在已构建的本地整机环境中验证两类错误排空
run_earlycheck_full.py	整机综合、厂家 SRAM 模型回放及 Formality 验证
run_power_recovery.py	同版功耗重放及所用工具版本兼容处理

表中脚本位于 experiments/q12_dense_20261113/ 及其 server/ 子目录。运行依赖授权工艺库、厂家模型和任务数据包；迁移环境时需配置依赖路径、运行目录及作业时限。具体依赖和调用参数见工程 README。

6.2 测试记录说明

图 10--14 为测试报告节选，依次包含性能汇总、未约束端点、SRAM 保持时间路径、功耗覆盖与模型警告、等价验证结果及未匹配点。

```
Q12 FINAL CANDIDATE - MEASUREMENT SNAPSHOT 2026-11-13T17:07:32.561225
TT 1.10 V / 25 C | 150 MHz | full 99 x 256 signed12 output | no output entropy codec
RUN /tmp/q12 earlycheck full y0zb5w2z
ENGINE 9447724c51ee9e4e80e72818cf1a448002b485fb00956be98d3f1a9f5848d432
NETLIST 3eb43b4d79bbeb0389f4bb272e93629e7241dc1a6186c4e6c37a8b7bd448b712

VENDOR FUNCTIONAL CASES: 12 / 12 PASS; real SRAM readback and bus conservation
THROUGHPUT: 6075.990386 tasks/s | mean 24687.333333 cycles | maximum 24802 cycles
INCREMENTAL AREA: 0.388582360 mm^2 | reference 0.448646863 mm^2 | change -13.388%
FULL SOC AREA: 2.730733915 mm^2
DC SETUP: 0.00000000 ns | DC HOLD: 0.00070456 ns
CHECK TIMING: unconstrained endpoints require review
FORMAL tool complete=True accepted=False
```

```
PT POWER RUN /tmp/q12_power_recovery_gghtgybp | reports_complete
Layer   Window (us)   Full-SoC power (mW)   Energy (uJ)
00      163.710294          58.500000            9.577052
01      164.696862          58.400000            9.618297
02      164.810184          58.400000            9.624915
03      164.570208          58.400000            9.610900
04      164.550210          58.300000            9.593277
05      163.530312          58.300000            9.533817
06      164.710194          58.300000            9.602604
07      164.283570          58.200000            9.561304
08      165.323466          58.400000            9.654890
09      164.323566          58.400000            9.596496
10      165.163482          58.300000            9.629031
11      165.036828          58.400000            9.638151
MEAN ENERGY 9.603394564 uJ | weighted POWER 58.358332546 mW
POWER ACCEPTANCE: False; annotation sources and check_power warnings require review

NOT OFFICIAL SIGNOFF: 600-sample accuracy and platform-loader acceptance remain open.
```

图 10　测试记录 A：周期、面积与时序汇总（上），12 个任务窗口的功耗及能量记录（下）。

```
Q12 TIMING AUDIT 2026-11-13T16:48:15.440749
SOURCE /tmp/q12_earlycheck_full_y0zb5w2z
FILE check timing after.rpt
Information: Checking generated_clocks...
Information: Checking loops...
Information: Checking no input delay...
Information: Checking unconstrained_endpoints...
Warning: The following end-points are not constrained for maximum delay.
End point
---------------
loader_clk
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart0/fifo_tx_data_reg[0]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart0/fifo_tx_data_reg[1]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart0/fifo_tx_data_reg[2]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart0/fifo_tx_data_reg[3]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart0/fifo_tx_data_reg[4]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart0/fifo_tx_data_reg[5]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart0/fifo_tx_data_reg[6]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart0/fifo_tx_data_reg[7]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart1/fifo_tx_data_reg[0]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart1/fifo_tx_data_reg[1]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart1/fifo_tx_data_reg[2]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart1/fifo_tx_data_reg[3]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart1/fifo_tx_data_reg[4]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart1/fifo_tx_data_reg[5]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart1/fifo_tx_data_reg[6]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart1/fifo_tx_data_reg[7]/D
u_e203_subsys_top/u_e203_subsys_main/u_e203_subsys_perips/u_perips_apb_uart2/fifo_tx_data_reg[0]/D
```

图 11 测试记录 B：check_timing 未约束端点报告节选。

```
Startpoint: u_fio/u_engine_fio/engine/compute/bias_load_q_reg[0][1]
Endpoint: u_fio/u_engine_fio/engine/compute/metadata_memory/stripe[1].g128.macro_ram
Path Group: core_clk
Path Type: min
slack (MET)                                                                0.00070456
Startpoint: u_fio/u_engine_fio/engine/compute/bias_load_q_reg[2][2]
Endpoint: u_fio/u_engine_fio/engine/compute/metadata_memory/stripe[1].g128.macro_ram
Path Group: core_clk
Path Type: min
slack (MET)                                                                0.00070456
Startpoint: u_fio/u_engine_fio/engine/compute/bias_load_q_reg[0][3]
Endpoint: u_fio/u_engine_fio/engine/compute/metadata_memory/stripe[2].g128.macro_ram
Path Group: core_clk
Path Type: min
slack (MET)                                                                0.00070456
Startpoint: u_fio/u_engine_fio/engine/compute/bias_load_q_reg[12][13]
Endpoint: u_fio/u_engine_fio/engine/compute/metadata_memory/stripe[2].g128.macro_ram
Path Group: core_clk
Path Type: min
slack (MET)                                                                0.00070456
Startpoint: u_fio/u_engine_fio/engine/compute/bias_load_q_reg[8][14]
Endpoint: u_fio/u_engine_fio/engine/compute/metadata_memory/stripe[2].g128.macro_ram
Path Group: core_clk
Path Type: min
slack (MET)                                                                0.00070456
Startpoint: u_fio/u_engine_fio/engine/compute/bias_load_q_reg[5][15]
Endpoint: u_fio/u_engine_fio/engine/compute/metadata_memory/stripe[2].g128.macro_ram
Path Group: core_clk
Path Type: min
slack (MET)                                                                0.00070456
```

图 12　测试记录 C：SRAM 数据路径保持时间报告节选，hold slack 为 +0.00070456 ns。

```
FILE read_saif.rpt
                                                None Found
instance    u_shared/u_storage/banks[9].slices[0].macro_ram/failedWrite
                                                None Found
instance    u_shared/u_storage/banks[9].slices[1].macro_ram/failedWrite
                                                None Found

================================================================================
Summary:
Total number of nets = 198844
Number of annotated nets = 47989 (24.13%)
Total number of leaf cells = 173948
Number of fully annotated leaf cells = 4413 (2.54%)
================================================================================

1
FILE check_power.rpt
Information: Checking 'out_of_table_range'.
Warning: There are 215 out_of_range ramps.
Warning: There are 2685 out_of_range loads.
Information: Checking 'missing_table'.
Information: Checking 'missing_function'.
Warning: There are 3 library cells without function.
0
FILE pin_attributes.rpt
activity_checker_status   pin        string     A
relative_toggle_rate      pin        double     A
static_probability        pin        float      A
toggle_rate               pin        double     A
x_probability             pin        float      A
MACRO_INPUTS 5986
SOURCE_COUNTS Counter({('UNKNOWN', 'UNKNOWN'): 5986})
```

图 13 测试记录 D：SAIF 活动覆盖统计、功耗模型警告及宏输入活动来源。

```
             Verification results may disagree with a logic simulator.
-----------------------------------------------------------------------
 Reference design: r:/WORK/qingyu_e203_soc_top
 Implementation design: i:/WORK/qingyu_e203_soc_top
 35565 Passing compare points
-----------------------------------------------------------------------------------------
Matched Compare Points     BBPin    Loop   BBNet     Cut    Port     DFF      LAT   TOTAL
-----------------------------------------------------------------------------------------
Passing (equivalent)        5986       0       0       0     251   29289       39   35565
Failing (not equivalent)       0       0       0       0       0       0        0       0
Not Compared
  Unread                       0       0       0       0       0     625        0     625
*****************************************************************************************
1
TOTAL_LINES 42
FORMAL_FILE unmatched_after_verify.rpt
***********************************************
Report         : unmatched_points
Reference      : r:/WORK/qingyu_e203_soc_top
Implementation : i:/WORK/qingyu_e203_soc_top
Version        : R-2020.09-SP5
Date           : Fri Nov 13 16:54:38 2026
***********************************************
9 Unmatched points (9 reference, 0 implementation):
  Ref  DFF0X      r:/WORK/qingyu_e203_soc_top/u_e203_subsys_top/u_e203_subsys_main/u_mem_merge/u_original/active_q_reg[0]
  Ref  DFF0X      r:/WORK/qingyu_e203_soc_top/u_e203_subsys_top/u_e203_subsys_main/u_mem_merge/u_original/active_q_reg[1]
  Ref  DFF0X      r:/WORK/qingyu_e203_soc_top/u_e203_subsys_top/u_e203_subsys_main/u_mem_merge/u_original/active_q_reg[2]
  Ref  DFF        r:/WORK/qingyu_e203_soc_top/u_e203_subsys_top/u_sirv_aon_top/u_sirv_aon_wrapper/u_sirv_aon/u_sirv_pmu/u_pmu_core/count_reg[15]
  Ref  DFF        r:/WORK/qingyu_e203_soc_top/u_fio/u_engine_fio/engine/decoder/symbol_value_reg[0]
  Ref  DFF        r:/WORK/qingyu_e203_soc_top/u_fio/u_engine_fio/engine/decoder/symbol_value_reg[1]
  Ref  DFF        r:/WORK/qingyu_e203_soc_top/u_fio/u_engine_fio/engine/decoder/symbol_value_reg[2]
  Ref  DFF        r:/WORK/qingyu_e203_soc_top/u_fio/u_engine_fio/engine/decoder/symbol_value_reg[3]
  Ref  DFF        r:/WORK/qingyu_e203_soc_top/u_fio/u_engine_fio/engine/decoder/symbol_value_reg[4]
```

图 14 测试记录 E：35565 个通过点、0 个失败点、625 个 unread 点及 9 个参考侧未匹配点。

参考文献

[1] 全国大学生嵌入式芯片与系统设计竞赛组委会. 芯片设计赛道赛题指南：正式赛题. 2026，15 页.

[2] 全国大学生嵌入式芯片与系统设计竞赛组委会. 芯片设计赛道赛题问题答复. 2026，4 页.

[3] 全国大学生嵌入式芯片与系统设计竞赛. 芯片设计赛道作品上传要求（初赛）. 2026.

[4] E203 hbirdv2 开源处理器工程. 随本设计归档的 RTL 与 LICENSE，参见冻结工程 `src/vendor/e203_hbirdv2/`.

[5] 轻语项目. Q12 native12 earlycheck 设计源码与测试记录. 2026-11-13. 标签 `q12-submission-20261113-r1`，提交 `8731bf4`.

[6] 轻语项目. 同版 DC、Formality、PrimeTime 原始报告及 VNC 记录. 2026-11-13，授权服务器工程留存；本报告列出源码与网表版本标识.